

Clase 4

Sofia

2026-09-01

```
knitr::opts_chunk$set(echo = TRUE)
library(here)
```

```
## here() starts at C:/Users/sofil/OneDrive/Documents/GitHub/lab-bitacora-Lapique
```

```
library(readr)
```

1. Construir la ruta relativa hacia el archivo CSV

```
archivo <- "cantidad_de_residuos_en_la_estacion_de_transferencia_2023.csv"
ruta_csv <- here("Datos", "Clase 4 - Residuos", archivo)
ruta_csv
```

```
## [1] "C:/Users/sofil/OneDrive/Documents/GitHub/lab-bitacora-Lapique/Datos/Clase 4 - Residuos/cantidad...
```

```
getwd()
```

```
## [1] "C:/Users/sofil/OneDrive/Documents/GitHub/lab-bitacora-Lapique/Codigos R/Clase 4 - Residuos"
```

2. Verificar que el archivo exista

```
if (!file.exists(ruta_csv)) {
  stop(paste("No se encontró el archivo en:", ruta_csv))
}
```

3. Cargar el archivo CSV

```
df <- read_csv(ruta_csv)
```

```
## Rows: 1222 Columns: 41
## -- Column specification -----
## Delimiter: ","
## chr (16): fecha_dia, fecha, matricula_letra, tipo_residuo_desc, subtipo_resi...
## dbl (15): pesada, tipo_residuo, subtipo_residuo, peso_netto, peso_bruto, tara...
## lgl (10): trayecto, trayecto_desc, tipo_recorrido, tipo_recorrido_desc, nome...
##
## i Use 'spec()' to retrieve the full column specification for this data.
## i Specify the column types or set 'show_col_types = FALSE' to quiet this message.
```

```
df
```

```
## # A tibble: 1,222 x 41
##   pesada fecha_dia      fecha matricula_letra tipo_residuo tipo_residuo_desc
##   <dbl> <chr>          <chr>    <chr>          <dbl> <chr>
## 1 3996241 30/11/23 00:00 30/11/~ SIM          1 TIPO DOMICILIARIO
## 2 3996243 30/11/23 00:00 30/11/~ SIM          1 TIPO DOMICILIARIO
## 3 3996253 30/11/23 00:00 30/11/~ SIM          1 TIPO DOMICILIARIO
## 4 3996276 30/11/23 00:00 30/11/~ SIM          1 TIPO DOMICILIARIO
## 5 3996298 30/11/23 00:00 30/11/~ SIM          1 TIPO DOMICILIARIO
## 6 3996303 30/11/23 00:00 30/11/~ SIM          1 TIPO DOMICILIARIO
## 7 3996305 30/11/23 00:00 30/11/~ SIM          1 TIPO DOMICILIARIO
## 8 3996344 30/11/23 00:00 30/11/~ SIM          1 TIPO DOMICILIARIO
## 9 3996380 30/11/23 00:00 30/11/~ SIM          1 TIPO DOMICILIARIO
## 10 3996400 30/11/23 00:00 30/11/~ SIM          1 TIPO DOMICILIARIO
## # i 1,212 more rows
## # i 35 more variables: subtipo_residuo <dbl>, subtipo_residuo_desc <chr>,
## #   peso_netto <dbl>, peso_bruto <dbl>, tara <dbl>, balanza <dbl>,
## #   medio_transp <dbl>, medio_transp_desc <chr>, trayecto <lgl>,
## #   trayecto_desc <lgl>, tipo_recorrido <lgl>, tipo_recorrido_desc <lgl>,
## #   tipo_volcado_desc <chr>, nomenclatura_circuito <lgl>, municipio <lgl>,
## #   lugar_salida <lgl>, lugar_salida_desc <lgl>, permiso <lgl>, ...
```

4. Inspección inicial de los datos

```
cat("--- Archivo cargado exitosamente desde:", basename(ruta_csv), "---\n")
```

```
## --- Archivo cargado exitosamente desde: cantidad_de_residuos_en_la_estacion_de_transferencia_2023.csv
```

```
print(spec(df)) # Muestra el tipo de dato asignado a cada columna
```

```
## cols(
##   pesada = col_double(),
##   fecha_dia = col_character(),
##   fecha = col_character(),
##   matricula_letra = col_character(),
##   tipo_residuo = col_double(),
##   tipo_residuo_desc = col_character(),
##   subtipo_residuo = col_double(),
##   subtipo_residuo_desc = col_character(),
##   peso_netto = col_double(),
##   peso_bruto = col_double(),
##   tara = col_double(),
##   balanza = col_double(),
##   medio_transp = col_double(),
##   medio_transp_desc = col_character(),
##   trayecto = col_logical(),
##   trayecto_desc = col_logical(),
##   tipo_recorrido = col_logical(),
##   tipo_recorrido_desc = col_logical(),
##   tipo_volcado_desc = col_character(),
```

```
## nomenclatura_circuito = col_logical(),
## municipio = col_logical(),
## lugar_salida = col_logical(),
## lugar_salida_desc = col_logical(),
## permiso = col_logical(),
## nro_permiso = col_double(),
## permiso_id = col_double(),
## tipo_permiso = col_double(),
## tipo_permiso_desc = col_character(),
## peso_authorized = col_logical(),
## destino_volcado = col_double(),
## destino_volcado_desc = col_character(),
## tipo_pesada = col_double(),
## tipo_pesada_desc = col_character(),
## basura_propia = col_character(),
## fmod = col_character(),
## viaje_fecha = col_character(),
## fecha_tara = col_character(),
## sitio = col_double(),
## sitio_desc = col_character(),
## tipo_movimiento = col_double(),
## tipo_movimiento_desc = col_character()
## )
```

```
head(df)
```

```
## # A tibble: 6 x 41
##   pesada fecha_dia      fecha matricula_letra tipo_residuo tipo_residuo_desc
##   <dbl> <chr>      <chr>      <chr>          <dbl> <chr>
## 1 3996241 30/11/23 00:00 30/11/2~ SIM              1 TIPO DOMICILIARIO
## 2 3996243 30/11/23 00:00 30/11/2~ SIM              1 TIPO DOMICILIARIO
## 3 3996253 30/11/23 00:00 30/11/2~ SIM              1 TIPO DOMICILIARIO
## 4 3996276 30/11/23 00:00 30/11/2~ SIM              1 TIPO DOMICILIARIO
## 5 3996298 30/11/23 00:00 30/11/2~ SIM              1 TIPO DOMICILIARIO
## 6 3996303 30/11/23 00:00 30/11/2~ SIM              1 TIPO DOMICILIARIO
## # i 35 more variables: subtipo_residuo <dbl>, subtipo_residuo_desc <chr>,
## #   peso_netto <dbl>, peso_bruto <dbl>, tara <dbl>, balanza <dbl>,
## #   medio_transp <dbl>, medio_transp_desc <chr>, trayecto <lgl>,
## #   trayecto_desc <lgl>, tipo_recorrido <lgl>, tipo_recorrido_desc <lgl>,
## #   tipo_volcado_desc <chr>, nomenclatura_circuito <lgl>, municipio <lgl>,
## #   lugar_salida <lgl>, lugar_salida_desc <lgl>, permiso <lgl>,
## #   nro_permiso <dbl>, permiso_id <dbl>, tipo_permiso <dbl>, ...
```

Data profiling/Inspección de datos/Reconocimiento de datos

Actividades esenciales:

- Evaluar el tamaño del archivo y las necesidades de procesamiento

```
file.size(ruta_csv)/1024
```

```
## [1] 363.9619
```

```
format(object.size(df), units = "MB")
```

```
## [1] "0.5 Mb"
```

Esto significa que ocupa 363.96 en el disco y 0.5MB en la memoria

- Evaluar si el caso a analizar está completo con los datos obtenidos: filas (unidades de observación) y columnas (características o variables)

```
dim(df)
```

```
## [1] 1222  41
```

```
range(df$fecha_dia)
```

```
## [1] "01/12/23 00:00" "31/12/23 00:00"
```

```
length(unique(df$fecha_dia))
```

```
## [1] 30
```

La BD tiene 1222 filas y 41 columnas. Las filas son todas distintas Hay datos de todo diciembre (del 1/12 al 30/12) y por eso son 30 datos

- Confirmar el tipo de datos obtenidos

```
# Son 3 formas de ver lo mismo, el tipo de dato almacenado en cada columna  
spec(df)
```

```
## cols(  
##   pesada = col_double(),  
##   fecha_dia = col_character(),  
##   fecha = col_character(),  
##   matricula_letra = col_character(),  
##   tipo_residuo = col_double(),  
##   tipo_residuo_desc = col_character(),  
##   subtipo_residuo = col_double(),  
##   subtipo_residuo_desc = col_character(),  
##   peso_netto = col_double(),  
##   peso_bruto = col_double(),  
##   tara = col_double(),  
##   balanza = col_double(),  
##   medio_transp = col_double(),  
##   medio_transp_desc = col_character(),  
##   trayecto = col_logical(),  
##   trayecto_desc = col_logical(),  
##   tipo_recorrido = col_logical(),  
##   tipo_recorrido_desc = col_logical(),  
##   tipo_volcado_desc = col_character(),
```

```
## nomenclatura_circuito = col_logical(),
## municipio = col_logical(),
## lugar_salida = col_logical(),
## lugar_salida_desc = col_logical(),
## permiso = col_logical(),
## nro_permiso = col_double(),
## permiso_id = col_double(),
## tipo_permiso = col_double(),
## tipo_permiso_desc = col_character(),
## peso_authorized = col_logical(),
## destino_vlcado = col_double(),
## destino_vlcado_desc = col_character(),
## tipo_pesada = col_double(),
## tipo_pesada_desc = col_character(),
## basura_propia = col_character(),
## fmod = col_character(),
## viaje_fecha = col_character(),
## fecha_tara = col_character(),
## sitio = col_double(),
## sitio_desc = col_character(),
## tipo_movimiento = col_double(),
## tipo_movimiento_desc = col_character()
## )
```

```
sapply(df, class)
```

```
##          pesada          fecha_dia          fecha
##          "numeric"          "character"          "character"
## matricula_letra          tipo_residuo          tipo_residuo_desc
##          "character"          "numeric"          "character"
## subtipo_residuo subtipo_residuo_desc          peso_netto
##          "numeric"          "character"          "numeric"
##          peso_bruto          tara          balanza
##          "numeric"          "numeric"          "numeric"
##          medio_transp          medio_transp_desc          trayecto
##          "numeric"          "character"          "logical"
##          trayecto_desc          tipo_recorrido          tipo_recorrido_desc
##          "logical"          "logical"          "logical"
##          tipo_vlcado_desc nomenclatura_circuito          municipio
##          "character"          "logical"          "logical"
##          lugar_salida          lugar_salida_desc          permiso
##          "logical"          "logical"          "logical"
##          nro_permiso          permiso_id          tipo_permiso
##          "numeric"          "numeric"          "numeric"
##          tipo_permiso_desc          peso_authorized          destino_vlcado
##          "character"          "logical"          "numeric"
## destino_vlcado_desc          tipo_pesada          tipo_pesada_desc
##          "character"          "numeric"          "character"
##          basura_propia          fmod          viaje_fecha
##          "character"          "character"          "character"
##          fecha_tara          sitio          sitio_desc
##          "character"          "numeric"          "character"
##          tipo_movimiento          tipo_movimiento_desc
##          "numeric"          "character"
```

```
str(df) # En clase usamos esta forma, lo que vemos entre "" son algunos valores de esa columna
```

```
## spc_tbl_ [1,222 x 41] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
## $ pesada : num [1:1222] 4e+06 4e+06 4e+06 4e+06 4e+06 ...
## $ fecha_dia : chr [1:1222] "30/11/23 00:00" "30/11/23 00:00" "30/11/23 00:00" "30/11/23 00:00" ...
## $ fecha : chr [1:1222] "30/11/23 08:28" "30/11/23 08:30" "30/11/23 08:36" "30/11/23 08:36" ...
## $ matricula_letra : chr [1:1222] "SIM" "SIM" "SIM" "SIM" ...
## $ tipo_residuo : num [1:1222] 1 1 1 1 1 1 1 1 1 1 ...
## $ tipo_residuo_desc : chr [1:1222] "TIPO DOMICILIARIO" "TIPO DOMICILIARIO" "TIPO DOMICILIARIO" "TIPO DOMICILIARIO" ...
## $ subtipo_residuo : num [1:1222] 1 1 1 1 1 1 1 1 1 1 ...
## $ subtipo_residuo_desc : chr [1:1222] "ASIMILABLE A DOMICILIARIO" "ASIMILABLE A DOMICILIARIO" "ASIMILABLE A DOMICILIARIO" "ASIMILABLE A DOMICILIARIO" ...
## $ peso_netto : num [1:1222] 11590 8660 6090 7920 9740 ...
## $ peso_bruto : num [1:1222] 28450 26070 25020 24720 26890 ...
## $ tara : num [1:1222] 16860 17410 18930 16800 17150 ...
## $ balanza : num [1:1222] 5 5 5 5 5 5 5 5 5 5 ...
## $ medio_transp : num [1:1222] 1 1 50 1 1 50 1 1 1 50 ...
## $ medio_transp_desc : chr [1:1222] "COMPACTADOR LEVANTE LAT." "COMPACTADOR LEVANTE LAT." "COMPACTADOR LEVANTE LAT." "COMPACTADOR LEVANTE LAT." ...
## $ trayecto : logi [1:1222] NA NA NA NA NA NA ...
## $ trayecto_desc : logi [1:1222] NA NA NA NA NA NA ...
## $ tipo_recorrido : logi [1:1222] NA NA NA NA NA NA ...
## $ tipo_recorrido_desc : logi [1:1222] NA NA NA NA NA NA ...
## $ tipo_volcado_desc : chr [1:1222] "SIN PERMISO" "SIN PERMISO" "SIN PERMISO" "SIN PERMISO" ...
## $ nomenclatura_circuito : logi [1:1222] NA NA NA NA NA NA ...
## $ municipio : logi [1:1222] NA NA NA NA NA NA ...
## $ lugar_salida : logi [1:1222] NA NA NA NA NA NA ...
## $ lugar_salida_desc : logi [1:1222] NA NA NA NA NA NA ...
## $ permiso : logi [1:1222] NA NA NA NA NA NA ...
## $ nro_permiso : num [1:1222] NA NA NA NA NA NA NA NA NA NA NA ...
## $ permiso_id : num [1:1222] NA NA NA NA NA NA NA NA NA NA NA ...
## $ tipo_permiso : num [1:1222] NA NA NA NA NA NA NA NA NA NA NA ...
## $ tipo_permiso_desc : chr [1:1222] NA NA NA NA ...
## $ peso_authorized : logi [1:1222] NA NA NA NA NA NA ...
## $ destino_volcado : num [1:1222] 34 34 34 34 34 34 34 34 34 34 ...
## $ destino_volcado_desc : chr [1:1222] "ETRA (Estacion de Transferencia)" "ETRA (Estacion de Transferencia)" "ETRA (Estacion de Transferencia)" "ETRA (Estacion de Transferencia)" ...
## $ tipo_pesada : num [1:1222] 1 1 1 1 1 1 1 1 1 1 ...
## $ tipo_pesada_desc : chr [1:1222] "AUTOMATICA" "AUTOMATICA" "AUTOMATICA" "AUTOMATICA" ...
## $ basura_propia : chr [1:1222] "NO" "NO" "NO" "NO" ...
## $ fmod : chr [1:1222] "16/01/24 10:41" "16/01/24 10:41" "16/01/24 10:41" "16/01/24 10:41" ...
## $ viaje_fecha : chr [1:1222] "29/11/23 00:00" "29/11/23 00:00" "30/11/23 00:00" "30/11/23 00:00" ...
## $ fecha_tara : chr [1:1222] "30/11/23 08:39" "30/11/23 08:40" "30/11/23 08:53" "30/11/23 08:53" ...
## $ sitio : num [1:1222] 2 2 2 2 2 2 2 2 2 2 ...
## $ sitio_desc : chr [1:1222] "ETRA" "ETRA" "ETRA" "ETRA" ...
## $ tipo_movimiento : num [1:1222] 1 1 1 1 1 1 1 1 1 1 ...
## $ tipo_movimiento_desc : chr [1:1222] "DESCARGA" "DESCARGA" "DESCARGA" "DESCARGA" ...
## - attr(*, "spec")=
## .. cols(
## ..   pesada = col_double(),
## ..   fecha_dia = col_character(),
## ..   fecha = col_character(),
## ..   matricula_letra = col_character(),
## ..   tipo_residuo = col_double(),
## ..   tipo_residuo_desc = col_character(),
## ..   subtipo_residuo = col_double(),
```

```
## .. subtipo_residuo_desc = col_character(),
## .. peso_netto = col_double(),
## .. peso_bruto = col_double(),
## .. tara = col_double(),
## .. balanza = col_double(),
## .. medio_transp = col_double(),
## .. medio_transp_desc = col_character(),
## .. trayecto = col_logical(),
## .. trayecto_desc = col_logical(),
## .. tipo_recorrido = col_logical(),
## .. tipo_recorrido_desc = col_logical(),
## .. tipo_voltado_desc = col_character(),
## .. nomenclatura_circuito = col_logical(),
## .. municipio = col_logical(),
## .. lugar_salida = col_logical(),
## .. lugar_salida_desc = col_logical(),
## .. permiso = col_logical(),
## .. nro_permiso = col_double(),
## .. permiso_id = col_double(),
## .. tipo_permiso = col_double(),
## .. tipo_permiso_desc = col_character(),
## .. peso_authorized = col_logical(),
## .. destino_voltado = col_double(),
## .. destino_voltado_desc = col_character(),
## .. tipo_pesada = col_double(),
## .. tipo_pesada_desc = col_character(),
## .. basura_propia = col_character(),
## .. fmod = col_character(),
## .. viaje_fecha = col_character(),
## .. fecha_tara = col_character(),
## .. sitio = col_double(),
## .. sitio_desc = col_character(),
## .. tipo_movimiento = col_double(),
## .. tipo_movimiento_desc = col_character()
## .. )
## - attr(*, "problems")=<pointer: 0x000001c7ca2fbe30>
```

Hay que identificar la unidad de observación Para eso reconozco las filas únicas: el ID de la BD

```
#Ejercicio identificar la variable ID
unique(df$matricula_letra) # Me muestra los valores de los valores únicos, en un vector
```

```
## [1] "SIM" "STP" "SCP" "SDA" "SCR" "SCX" "SCS" "SDB" "SDC" "SCM" "SCO" "SCI"
```

```
length(unique(df$matricula_letra)) # Me muestra la cantidad de los valores únicos
```

```
## [1] 12
```

```
sapply(df, function(x) length(unique(x)))
```

```
##           pesada           fecha_dia           fecha
##           1222             30         1217
```

##	matricula_letra	tipo_residuo	tipo_residuo_desc
##	12	6	6
##	subtipo_residuo	subtipo_residuo_desc	peso_netto
##	14	14	783
##	peso_bruto	tara	balanza
##	892	462	1
##	medio_transp	medio_transp_desc	trayecto
##	12	12	1
##	trayecto_desc	tipo_recorrido	tipo_recorrido_desc
##	1	1	1
##	tipo_volcado_desc	nomenclatura_circuito	municipio
##	2	1	1
##	lugar_salida	lugar_salida_desc	permiso
##	1	1	1
##	nro_permiso	permiso_id	tipo_permiso
##	14	14	2
##	tipo_permiso_desc	peso_authorized	destino_volcado
##	2	1	1
##	destino_volcado_desc	tipo_pesada	tipo_pesada_desc
##	1	1	1
##	basura_propia	fmod	viaje_fecha
##	1	11	33
##	fecha_tara	sitio	sitio_desc
##	1219	1	1
##	tipo_movimiento	tipo_movimiento_desc	
##	1	1	